

骆俊杰

姓名: 骆俊杰 电话: 13794671810 邮箱: 836615903@qq.com
GitHub: github.com/defaultlj 作品集网站: https://defaultlj.github.io

求职意向

投递类型: 实习 (在校生) 目标职位: AI 开发 / Java 开发 意向城市: 深圳 到岗: 可协商

教育背景

广东海洋大学 · 数学与计算机学院 2023.09 — 2027.06
数据科学与大数据技术 · 本科 英语 CET-4 490 分
主修课程: 机器学习、深度学习、自然语言处理、数据结构与算法

专业技能

编程语言	熟练使用 Python (FastAPI、PyTorch)、Java (Spring Boot), 了解 JavaScript/Node.js; Git 管理项目
大模型应用	独立完成 38K★ 开源 RAG 平台 (Langchain-Chatchat) 本地化部署与源码研读; 掌握 Prompt 工程 (Few-shot / CoT / 结构化输出), 熟悉 Function Calling; 使用过 LangChain / LangChain4j
AI Agent	理解 ReAct 范式; 实践任务规划 + 工具调用 + 多轮记忆; 为纯文本模型 Agent 按轮次路由集成 14 个视觉工具
端侧 AI	PyTorch → ONNX 导出与 ONNX Runtime 推理; INT8 量化 (PTQ/QDQ) 与精度 / 时延评估; Android 真机部署; MediaPipe + OpenCV 实时手势识别
Java 全栈	Spring Boot + MyBatis-Plus + JWT/RBAC; Vue3 前后端分离; SSE 流式输出; 85 个单元测试的工程质量实践
工程素养	日志监控、Bad Case 分析、效果回归测试、异常降级方案设计; 沉淀 7 条部署踩坑记录

项目经历

- 一、端侧 AI 部署实验 (ONNX 量化 + Android 真机)

2026.08—09 · 个人

GitHub: github.com/defaultlj/onnx-edge-quant-lab

 - PyTorch→ONNX→ORT 全链路打通, 导出与 ORT 推理输出最大数值差 $1.6e-7$; MobileNetV2 INT8 量化 (PTQ/QDQ) 后体积 13.3 MiB → 3.4 MiB, 减少 74%
 - 自量化模型部署到 Android 真机 (CameraX + ORT), 各跑 500+ 帧: median 延迟 11-14.5 ms, 比 FP32 快 2.2 倍; 同一模型在 PC 上反而慢 47% (ORT 的 PyPI wheel 未编译 VNNI 内核, 手机 ARM dotprod 生效)
- 二、Langchain-Chatchat 源码研读与 RAG 检索改造

2026.07—08 · 个人

GitHub: github.com/defaultlj/lc-chat-chat (已部署可运行)

 - 部署落地: conda + DeepSeek API + bge-m3 本地 Embedding + FAISS, 知识库向量化上线, 记录 7 条踩坑
 - 源码研读: KBService 抽象基类 + 工厂模式 (6 种向量库可插拔), 规划 BM25 + 向量 + RRF 混合检索改造
 - 修复 WebUI 上游 bug (use_mcp 未初始化引用) 并拟提交 PR; Bad Case 实验验证 system prompt 约束必要性 (小模型伪造工具调用、DeepSeek 训练数据污染)
- 三、校园二手交易平台 (AI 助手「小营」)

2026.05—08 · 个人

GitHub: github.com/defaultlj/Campus-Trading

 - 全栈: 10 个 Controller、30+ REST 接口、Vue3 前端; MyBatis-Plus 多条件检索, 7 张表 CRUD + 事务

- 质量保障：85 个单元测试全部通过，暴露并修复 5 个业务 bug（含 SQL 优先级漏洞），每处修复补回归测试
- AI 助手「小营」：LangChain4j + DeepSeek，SSE 流式输出；关键词驱动检索数据库真实数据拼入上下文，回答可溯源

四、DeepSeek Harness 视觉路由集成

2026.08 · 个人

GitHub: github.com/defaultlj/dsh-vision-integration

- 为纯文本会话模型零更换引入视觉能力：按轮次路由，含图轮次切视觉模型、文字轮次保持原模型，成本与上下文零影响
- 交付 14 个视觉工具（图片问答 / OCR / 像素对比）零事故；动态 import 预检与 bundle 注册逐项验证，杜绝 invalid plugin 崩溃
- 复盘历史事故形成崩溃处理手册（7 类症状速查 + 分级恢复流程 + 6 条预防铁律），部署前完成配置备份

五、人力资源管理系统（自然语言指令驱动）

2026.03—05 · 个人

GitHub: github.com/defaultlj/spring-demo-1

- AIDispatcherService 双层指令分发：规则优先（正则 / 关键词路由，零延迟零幻觉）+ DeepSeek 兜底模糊指令
- 原生 HttpURLConnection + Gson 自研 DeepSeek 调用（无 SDK 依赖），完整理解 LLM API 请求-响应结构；踩坑 429 限流后补指数退避重试
- JWT 认证拦截器 + RBAC 角色权限（RoleEnum + UserContext）

六、MediaPipe + OpenCV 实时手势识别

2026.06—07 · 个人

GitHub: github.com/defaultlj/VisionLab

- MediaPipe HandLandmarker（新版 Task API）检测 21 个关键点，OpenCV 实时绘制骨架，支持双手同检
- 手指计数用指尖与相邻关节的相对位置做几何判定；拇指弯曲方向垂直且左右手规则相反，需先判左右手

七、AI 辅助开发的记账 App

2026.06—08 · 个人

GitHub: github.com/defaultlj/vibe-1

- 与 AI Agent 协作走完需求拆解 → 方案设计 → 分模块实现 → 测试验收全流程（Node.js + Express + Jest）
- AI 代码审查三层防线：审查清单（边界 / 异常 / 并发 / 注入）+ 测试驱动 + 小步迭代；实例：审查发现 AI 生成代码缺空值检查并修复
- 以「有罪推定」心态对待 AI 生成代码（默认有问题，直到测试证明），形成个人 AI 协作工作流文档

自我评价

- 对 AI 工程化落地有浓厚兴趣：关注「模型可用、系统稳定、体验可交付」；独立完成 RAG 平台部署、Agent 视觉集成、Java 业务 + AI 集成等端到端项目
- 完整闭环能力：需求拆解 → 方案设计 → 编码实现 → 效果评估；产出 85 个单测、7 条踩坑记录、Bad Case 实验集
- 工作方式：人机协同开发 + 测试兜底 + 文档沉淀；作品集网站（defaultlj.github.io）与开源仓库持续公开产出
- 学习能力强：系统研读 Transformer 论文源码、RAG 全链路，形成完整学习笔记体系；能把技术方案讲清楚（文档、演示、代码走查）
- 理解端侧场景的工程约束（延迟 / 功耗 / 离线），对 AI 应用落地有真实用户视角